


A series of thin, black, overlapping lines forming various geometric shapes like triangles and polygons, creating a complex, abstract pattern in the upper left portion of the slide.

PITCH

Gabriel Dimas

Pós-Graduação em  
Data Science



BANCO DA  
PRAÇA

# CHURN

Desafio: Saída de Clientes

Dados: Perfil dos Clientes

Abordagem: Machine  
Learning como aliado

Sugestões e Perspectivas



# DESAFIO: MANTER CLIENTES

Segundo pesquisa da Boston Consulting Group divulgada em 2017, os bancos perdiam de 10% a 15% de sua receita bruta anual por churn.



# O QUE OS DADOS REVELAM

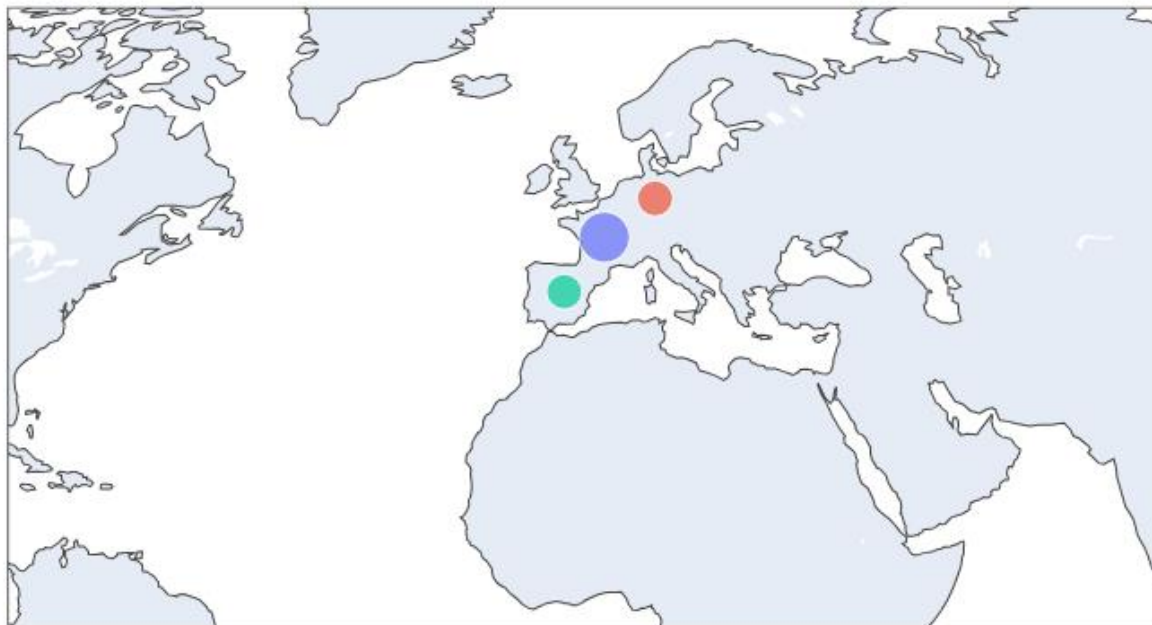
Nossa base tem 10.000 clientes

**75%** têm até 44 anos de idade

Cerca de **20%** do total deixaram os serviços

# 50% são franceses

País de Localização dos Clientes



País

- França
- Alemanha
- Espanha

Mais de **40%** têm no mínimo **2** produtos


Todos que adquiriram **4** produtos não continuaram



Quase **70%** têm cartão de crédito


Menos de **6%** permanecem mais de **10** anos

# Clientes com saldo bancário maior tendem a deixar os serviços



Possibilidade: Clientes estão indo para outro Banco que ofereça soluções adaptadas para poder aquisitivo maior e diversificação de investimentos.

Proposta: Criar uma divisão no Banco para estes clientes.



COMO MACHINE  
LEARNING PODE  
NOS AJUDAR



## **Algoritmos de Machine Learning**

Usando os dados do dataset, podemos prever os padrões envolvidos na dinâmica de saída de clientes. Uma vez traçado o perfil do cliente, poderá ser direcionado para a divisão VIP do Banco.



## AVALIAÇÃO DO MODELO UTILIZADO

O modelo de Machine Learning utilizado conseguiu prever com sensibilidade de 76% a saída de clientes.

Há espaço para melhorias e aprimoramentos.

Com esse conhecimento, é possível indicar aos clientes a adoção dos serviços da nova divisão.



## SUGESTÕES E PERSPECTIVAS

Coleta de novas features para que seja calculada a Life-Time Value(LTV) de cada cliente. Seria relevante obter os dados de quanto cada cliente paga em taxas por produto bancário. Dessa maneira, será possível aprimorar o modelo. Além disso, é importante trackear continuamente o desempenho do modelo caso seja de fato implementado.



## PARA MAIS INFORMAÇÕES

Caso queira avaliar a investigação do dataset, acesse o endereço ao lado.

No repositório estão disponíveis a Análise Exploratória e a construção do modelo a ser implementado, no caso, o LightGBM, com Sensibilidade(Recall) de 76%.



[GabrielGDimas/churn\\_project \(github.com\)](https://github.com/GabrielGDimas/churn_project)



# OBRIGADO

Gabriel Dimas

[gabrielgoulartdimas@gmail.com](mailto:gabrielgoulartdimas@gmail.com)

<https://www.linkedin.com/in/gabrielgdimas>